

Semestrální zkouška IKR - 17. 5. 2016,

Login:

Podpis:

-
1. Co to je Detection Error Trade-off (DET) křiva? Čemu odpovídá jeden konkrétní bod na této křivce? Čemu pro takový bod odpovídají hodnoty na x-ové a y-nové souřadnici? Jak vytvoříme DET křivku (jak získáme různé body na této křivce) pro jeden konkrétní detekční systém?

-
2. Co rozumíme pojmem "generalizace klasifikátoru"?

-
3. Klasifikátory můžeme rozdělit na generativní (např. lineární gaussovský klasifikátor, klasifikátory založené na GMM a HMM, ...) a diskriminativní (např. logistická regrese, SVM, neuronové sítě, ...). Vysvětlete v čem se tyto dva přístupy liší a jaké jsou jejich výhody a nevýhody.

-
4. Popište, jak provedeme klasifikaci nového vzoru metodou K-nejbližších sousedů (K-nearest neighbours).

-
5. Jak pracuje klasifikátor založený na metodě k-nejbližších sousedů (K-nearest neighbours). Jaké jsou jeho výhody a nevýhody?

-
6. U jednotlivých trénovacích vzorů často předpokládáme, že jsou na sobě statisticky nezávislé. Co to znamená? Jaká výhoda či zjednodušení z toho plyne pro trénování klasifikátoru? Např. uvažujte jakou formu v takovém případě má Maximum Likelihood objektivní funkce.

-
7. Co to je apriorní pravděpodobnost a jakou hraje roli při maximum a-posteriori klasifikaci (MAP classification)?

-
8. Co je klasifikační pravidlo maximální aposteriorní pravděpodobnosti (Maximum a-posteriori - MAP). Uveďte příklad nějakého konkrétního klasifikátorů, u kterého toto pravidlo můžeme použít.

-
9. Mějme natrénované pravděpodobnostní modely (např. GMM) popisující rozložení hustoty pravděpodobnosti příznaků $p(\mathbf{x}|C_1)$ a $p(\mathbf{x}|C_2)$ dvou tříd C_1 a C_2 . Pro trénování těchto modelů jsme měli k dispozici 1000 trénovacích vzorů pro třídu C_1 a 2000 trénovacích vzorů pro třídu C_2 . Víme ale, že v cílové aplikaci nám bude přicházet desetkrát více vzorů z třídy C_1 , než z třídy C_2 . Napište, jak v cílové aplikaci budeme klasifikovat nově přichozí vzor x , tak abychom minimalizovali pravděpodobnost chyby.

-
10. Napište bayesův vzorec/teorém (Bayes rule). Popište jednotlivé výrazy v tomto vzorci. Popište jak se tento vzorec využije při klasifikaci pomocí nějakého generativního modelu (např. Gaussovský model nebo GMM) a jak v takovém případě získáme jednotlivé výrazy v bayesově vzorci.

-
11. Jedno procento populace má určitou nemoc. U testovaných osob trpících touto nemocí je test pozitivní v polovině případů. Test je ovšem pozitivní také pro 5% osob, které touto nemocí netrpí. Jestliže u náhodně vybrané osoby má test pozitivní výsledek, jaká je pravděpodobnost, že je tato osoba skutečně nemocná?

-
12. Jak odhadnu podmíněnou pravděpodobnost, že dostanu infarkt když budu tlustý $P(\text{infarkt}|\text{tlustý})$ pokud mám statistiky pořízené na velkém vzorku populace, kde je u každého člověka záznam o tom

zda byl tlustý a zda prodělal infarkt.

-
13. Na velkém vzorku N žen jsme provedli průzkum a rozdělili je do dvou tříd *hloupá*, *chytrá*. Současně jsme si u každého pozorovaného subjektu poznamenali, zda se jednalo o blondýnku či nikoli. Jak z našich sezbíraných statistik odhadneme podmíněnou pravděpodobnost $P(\textit{hloupá}|\textit{blondýnka})$, když budeme naivně předpokládat, že hloupost žen záleží pouze na barvě vlasů.

-
14. Co to je obecně (pro jakýkoli pravděpodobnostní model) odhad parametrů s maximální věrohodnosti (Maximum Likelihood - ML)? Co je vstupem a výstupem tohoto procesu? Jakou objektivní funkci se snažíme maximalizovat? Napište alespoň obecný matematický výraz. Jaké parametry odhadujeme? Uveďte příklad.

-
15. Odhad střední hodnoty jednorozměrného gaussovského rozložení s maximální věrohodností (Maximum Likelihood) je prostý průměr trénovacích dat: $\mu = \frac{1}{N} \sum_{n=1}^N x_n$. Popište, jak se k tomuto výsledku dojde. Napište vzoreček objektivní funkce, kterou se snažíme maximalizovat (stačí v obecné podobě pro jakýkoli model). Naznačte postup řešení. Plné odvození bude oceněno bonusovým bodem.

-
16. Pro maximum likelihood trénování modelu směsice gaussovských rozložení (Gaussian Mixture Model - GMM) používáme "Expectation Maximization" (EM) algoritmus, který sestává ze dvou kroků, které iterativně provádíme. Popište tyto kroky. Co se ve kterém kroku odhaduje a jak na sobě tyto kroky závisí? Rozhodnete-li se zapsat kroky konkrétními vzorečky, vysvětlíte slovně jejich význam.
-

17. Model směsice gausovských rozložení (Gaussian Mixture Model) lze interpretovat jako model s takzvanou skrytou (latentní) náhodnou proměnnou. Co tato skrytá proměnná reprezentuje? Jakou hraje roli při vyhodnocení hustoty pravděpodobnosti (likelihood) $p(\mathbf{x})$?

-
18. Pro řešení klasifikační úlohy chceme použít generativní klasifikátor, kde jsou rozložení jednotlivých tříd modelována pomocí směsice gausovských rozložení (GMM). Bohužel nemáme mnoho trénovacích dat pro odhad GMM parametrů. Navrhněte co dělat, aby výsledný klasifikátor dobře generalizoval pro nová data.

-
19. Co to je extrakce příznaků (feature extraction)? K čemu slouží? Jaké vlastnosti by měly příznaky mít?

-
20. Mějme vícerozměrná data $\mathbf{x}$ generovaná ze standardního normálního rozložení $\mathcal{N}(\mathbf{x}; \mathbf{0}, \mathbf{I})$. Nová data $\mathbf{y} = \mathbf{A}\mathbf{x}$ získáme lineární transformací původních dat. Jak se změní rozložení po transformaci dat pokud bude mít transformační matice $\mathbf{A}$ ortonormální báze (tedy $\mathbf{A}\mathbf{A}^T = \mathbf{A}^T\mathbf{A} = \mathbf{I}$)? Jaké konkrétní hodnoty budou mít vlastní čísla kovarianční matice Σ_y transformovaných dat?

-
21. Mějme data vygenerovaná z vícerozměrného gaussovského rozložení $\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Existuje taková transformace $\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b}$, která transformuje data do standardního normálního rozložení $\mathbf{y} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ (tedy nová střední hodnota je nulový vektor $\mathbf{0}$ a kovarianční matice je jednotková matice $\mathbf{I}$). Jak získáme matici $\mathbf{A}$ a vektor $\mathbf{b}$ takovéto transformace.

Pomůcka: Uvědomte si kroky, které je nutné udělat: 1) posunout data tak aby měla nulovou střední hodnotu, 2) rotovat data tak, aby měla diagonální kovarianční matici, 3) podělit jednotlivé dimenze standardní odchylkou, tak aby byly variance ve všech dimenzích jednotkové. Pozor na pořadí těchto kroků a na pořadí operací v transformačním vzorečku.


-
22. Mějme dvě jednorozměrné náhodné veličiny x a y s gaussovskými rozloženími $\mathcal{N}(x; \mu_x, \sigma_x^2)$ a $\mathcal{N}(y; \mu_y, \sigma_y^2)$. Jaké bude společné (dvourozměrné) rozložení pravděpodobnosti $p(x, y)$ za předpokladu, že jsou obě náhodné veličiny na sobě statisticky nezávislé? Uveďte přesnou podobu tohoto rozložení a parametrů, které toto rozložení popisují.

-
23. Mějme kovarianční matici odhadnutou na určité množině vícerozměrných trénovacích dat. Vlastní čísla této kovarianční matice odpovídají jistým variancím v těchto trénovacích datech. O jaké variance se jedná?

-
24. Co to je “analýza hlavních komponent (Principal Component Analysis)”? Kdy, jak, a k čemu se používá?

-
25. Jaký je rozdíl mezi analýzou hlavních komponent (PCA) a lineární diskriminační analýzou (LDA)? K čemu tyto techniky slouží? V jakých případech kterou techniku použijete?
-
26. Mějme natrénovaný pravděpodobnostní lineární klasifikátor pro dvě třídy (např. pomocí logistické regrese). Jakou podobu budou mít parametry tohoto klasifikátoru? Jak na základě těchto parametrů rozhodneme do které třídy patří nový příchozí vzor $\mathbf{x}$? Jak spočítáme posteriorní pravděpodobnost, že tento vzor patří do jedné či druhé třídy?
-
27. Mějme lineární klasifikátor pro dvě třídy popsany rovnicí $y(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$. Popište, jak se změní rozhodovací hranice (hyperrovina oddělující třídy), když se zmenší absolutní hodnota parametru w_0 .
-

-
28. Mějme lineární klasifikátor pro dvourozměrná data $\mathbf{x} = [x_1, x_2]^T$ a dvě třídy popsané rovnicí $y(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$. Zakreslete do os, kudy vede hranice mezi třídami pro $\mathbf{w}^T = [6.0, 8.0]$ a $w_0 = -48.0$.




-
29. Popište, jaké úlohy je schopen řešit Perceptron. V jakých případech trénování selže? V jakých případech je naopak trénovací algoritmus úspěšný a co je v takovém případě jeho řešení? Proč ale může být toto řešení suboptimální (ve srovnání např. s SVM).

-
30. Logistická regrese i lineární gaussovský klasifikátor (kde je rozložení vzorů jednotlivých tříd modelováno gaussovskými se sdílenou kovarianční maticí) jsou oba lineární klasifikátory. Uvažujme pouze klasifikační problém se dvěma třídami C_1 a C_2 . Pro oba klasifikátory vyhodnotíme posteriorní pravděpodobnost $P(C_1|\mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x} + w_0)$, kde $\mathbf{x}$ je nějaký testovací vzor. Pro logistickou regresi i lineární generativní klasifikátor je tedy vyhodnocení klasifikátoru naprosto shodné. V čem a jak se tedy tyto klasifikátory liší? Jaké jsou jejich výhody a nevýhody?

-
31. Vysvětlete k čemu obecně slouží a na jakém principu pracuje Newton-Raphson optimalizační metoda (kterou jsme využívali pro trénování logistické regrese)? V čem se tato metoda liší od metody největšího spádu (gradient descent) a jaké má výhody?
-

32. Pro trénování logistické regrese i klasifikační neuronové sítě používáme stejnou objektivní (chybovou) funkci, kterou se snažíme optimalizovat. O kterou objektivní funkci se jedná? Napište tuto objektivní funkci, vysvětlete jednotlivé symboly a řeknete co tato funkce vyjadřuje.
-
33. Vysvětlete k čemu slouží a na jakém principu pracuje metoda největšího spádu (gradient descent)? Jaký vztah má tato metoda k algoritmu zpětného šíření chyby (error back-propagation), který se používá k trénování neuronových sítí.
-
34. Mějme binární klasifikační problém s třídami A a B . Neuronová síť s topologií, vahami (weights) a prahy (biases) uvedenými na obrázku predikuje pravděpodobnost třídy A pro vstupní vektor $\mathbf{x}$. Všechny aktivační funkce jsou logistické sigmoidy $\sigma(a) = 1/(1 + \exp(-a))$. Která třída bude podle této neuronové sítě pravděpodobnější pro vstup $\mathbf{x} = [x_1, x_2] = [2.0, 1.0]$? Ukažte proč.



35. Při trénování neuronové sítě můžeme použít různé strategie úpravy vah: "standardní" metoda gradientního sestupu (batch training), mini-batch trénování, Stochastic Gradient descent. Jak se tyto

přístupy liší?

36. K čemu slouží rekurentní neuronové sítě a jak se liší od dopředných neuronových sítí?

37. Jakou operaci provede pooling vrstva v konvoluční síti?

38. Jaké jsou možnosti použití lineárních klasifikátorů pro řešení nelineárních klasifikačních problémů?

39. Nakreslete nějaká dvourozměrná data pro dvě lineárně separovatelné třídy a ukažte jaké řešení pro klasifikaci takových dat nabídne lineární SVM klasifikátor. Vysvětlete jak se k tomuto řešení dojde.


40. Co to je jádrová funkce (kernel function) u SVM klasifikátoru? Co jsou vstupy a co je výstupem takové funkce? K čemu jádrová funkce u SVM klasifikátoru slouží? Jaký problém nám pomáhá řešit a jak?

-
41. Mějme jádrovou funkci (kernel function) $K(x, y) = (1 + xy)^2$ definovanou pro skalární vstupy x a y . Tato funkce se dá interpretovat jako 1) nelineární expanze skalárů x a y do třírozměrných vektorů a 2) výpočet skalárního součinu mezi těmito vektory. O jakou konkrétní nelineární expanzi se jedná? Odvoďte!

-
42. Vysvětlete jaké řešení hledá SVM klasifikátor, který řeší problémy s překrývajícími se třídami pomocí tzv. "slack variables".


-
43. Co jsou to skryté markovovy modely (Hidden Markov Models)? Co modelují či reprezentují? Jakou podobu mají vzory, které pomocí těchto modelů můžeme klasifikovat (nebo z nich náhodně generovat)?

44. Skrytý markovův model (Hidden Markov Model) na obrázku má tři stavy $\{1, 2, 3\}$, přechodové pravděpodobnosti $\{a_{11}, a_{12}, a_{22}, a_{23}, a_{33}, a_{3exit}\}$ a funkce $\{b_1(\mathbf{x}), b_2(\mathbf{x}), b_3(\mathbf{x})\}$ pro výpočet hodnot hustoty pravděpodobnosti pro jednotlivé stavy pro určitý rámec $\mathbf{x}$. Mějme sekvenci čtyř rámců (příznakových vektorů) $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3, \mathbf{x}_4]$. Pomocí zmíněných symbolů napište jak se spočítá podmíněná věrohodnost (pravděpodobnost) $p(\mathbf{X}|\mathbf{S})$ pro sekvenci stavů $\mathbf{S} = [1, 2, 3, 3]$. Jak se dále spočítá pravděpodobnost této sekvence stavů $P(\mathbf{S})$.



45. Pro skrytý markovův model z předchozího příkladu uveďte jak se vyhodnotí věrohodnost $p(\mathbf{X})$.

46. Skrytý markovův model (Hidden Markov Model) na obrázku má tři stavy $\{1, 2, 3\}$, přechodové pravděpodobnosti $\{a_{11}, a_{12}, a_{22}, a_{23}, a_{33}, a_{3exit}\}$ a funkce $\{b_1(\mathbf{x}), b_2(\mathbf{x}), b_3(\mathbf{x})\}$ pro výpočet hodnot hustoty pravděpodobnosti pro jednotlivé stavy pro určitý rámec $\mathbf{x}$. Mějme sekvenci čtyř rámců (příznakových vektorů) $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3, \mathbf{x}_4]$. Pomocí zmíněných symbolů napište jak se pro tento model spočítá věrohodnost (pravděpodobnost) této sekvence příznaků $p(\mathbf{X})$. Mějte na paměti, že pro vyhodnocení modelu je třeba brát v úvahu všechny možné skryté sekvence stavů.



-
47. Skryté markovovy modely jsou generativním modelem popisujícím rozložení hustoty pravděpodobnosti vzorů, kde každý vzor je sekvence příznakových vektorů. Jako každý generativní model nám tedy

umožňují náhodně generovat vzory z rozložení které reprezentují. Popište jak byste náhodně vygenerovali jeden vzor ze skrytého markovova modelu z předchozího příkladu.

-
48. Co je ve skrytých makrovových modelech "skryté", tedy co nelze přímo vypořádat ze vstupní (viděné) sekvence příznaků?