

Strojové učení a rozpoznávání

Lineární klasifikátory

Lukáš Burget




Duben 2026

Opakování - Skalární součin

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \quad \mathbf{w} = \begin{bmatrix} w_1 \\ w_2 \end{bmatrix}$$

$$\mathbf{w}^T \mathbf{x} = [w_1 \quad w_2] \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = w_1 x_1 + w_2 x_2$$



Lineární klasifikátor

$$y(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$$


Vyber třídu C_1 pokud $y(\mathbf{x}) > 0$ a jinak vyber třídu C_2

Zobecněný lineární klasifikátor

$$y(\mathbf{x}) = f(\mathbf{w}^T \mathbf{x} + w_0)$$

kde f se nazývá aktivační funkce

Lineární klasifikátor



$$y(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$$

$$\frac{\mathbf{w}^T \mathbf{x}}{|\mathbf{w}|} = -\frac{w_0}{|\mathbf{w}|} + \frac{y(\mathbf{x})}{|\mathbf{w}|}$$

Perceptron

- Jednoduchý lineární klasifikátor s aktivační funkcí:

$$f(a) = \begin{cases} +1, & a \geq 0 \\ -1, & a < 0 \end{cases}$$

- Samotná aktivační funkce v tomto případě nic nezmění – rozhodování na základě $y(\mathbf{x}) > 0$ by vedlo ke stejnému výsledku – ale pro učící se algoritmus bude výhodné definovat si požadovaný výstup jako:

$$t \in \{-1, +1\}$$

- Pro další zjednodušení předpokládejme, že w_0 je “nulový” koeficient vektoru $\mathbf{w}$ a odpovídající vstup x_0 je vždy 1. Můžeme tedy psát pouze:

$$y(\mathbf{x}) = f(\mathbf{w}^T \mathbf{x})$$

Perceptron – učící algoritmus





- Cyklicky procházej jednotlivé trénovací vzory $\mathbf{x}_n$ a vždy když narazíš na špatně klasifikovaný vzor kde

$$y(\mathbf{x}_n) \neq t_n$$

změň vektor $\mathbf{w}$ takto:



$$\mathbf{w}^{\tau+1} = \mathbf{w}^{\tau} + \mathbf{x}_n t_n$$

- Lze dokázat, že pokud jsou data lineárně separovatelná, tak, algoritmus vždy nalezne řešení – konverguje.
V opačném případě, ale nikdy nekonverguje



Perceptron

- Ale které řešení je to správné?
- Řešení, které poskytne učící algoritmus perceptronu záleží na inicializaci – počátečním w
- Algoritmus konverguje v méně než $(R/D)^2$ krocích



Opakování - MAP klasifikátor

- Mějme 2 třídy C_1 a C_2
 - Pro daný příznak $\mathbf{x}$ vyber třídu C s větší posteriorní pravděpodobností $p(C|\mathbf{x})$
 - Vyber C_1 pouze pokud:

$$P(C_1|\mathbf{x}) > P(C_2|\mathbf{x})$$

$$\frac{p(\mathbf{x}|C_1)P(C_1)}{\cancel{p(\mathbf{x})}} > \frac{p(\mathbf{x}|C_2)P(C_2)}{\cancel{p(\mathbf{x})}}$$

$$\ln p(\mathbf{x}|C_1) + \ln P(C_1) > \ln p(\mathbf{x}|C_2) + \ln P(C_2)$$

$$\ln \frac{p(\mathbf{x}|C_1)}{p(\mathbf{x}|C_2)} + \ln \frac{P(C_1)}{P(C_2)} > 0$$

Pravděpodobnostní generativní model

- Modelujme rozložení tříd gaussovským rozložením:



$$p(\mathbf{x}|C_k) = \frac{1}{(2\pi)^{D/2}} \frac{1}{|\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_k)^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}_k) \right\}$$

- Pokud náš model omezíme tak, že každá třída má svou střední $\boldsymbol{\mu}_k$ hodnotu, ale kovarianční matice $\boldsymbol{\Sigma}$ je společná pro obě třídy, tak můžeme psát:

$$y(\mathbf{x}) = \ln \frac{p(\mathbf{x}|C_1)}{p(\mathbf{x}|C_2)} + \ln \frac{P(C_1)}{P(C_2)} = \mathbf{w}^T \mathbf{x} + w_0$$

kde

$$\begin{aligned} \mathbf{w} &= \boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) \\ w_0 &= -\frac{1}{2} \boldsymbol{\mu}_1^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_1 + \frac{1}{2} \boldsymbol{\mu}_2^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_2 + \ln \frac{P(C_1)}{P(C_2)} \end{aligned}$$



Maximum likelihood odhad parametrů

- Hledáme parametry modelu



$$\{\hat{\boldsymbol{\mu}}_1, \hat{\boldsymbol{\mu}}_2, \hat{\boldsymbol{\Sigma}}\} = \arg \max_{\{\boldsymbol{\mu}_1, \boldsymbol{\mu}_2, \boldsymbol{\Sigma}\}} \prod_{n=1}^N \mathcal{N}(\mathbf{x}_n; \boldsymbol{\mu}_{t_n}, \boldsymbol{\Sigma})$$

kde t_n je třída, do které patří vzor $\mathbf{x}_n$ a $\boldsymbol{\mu}_{t_n}$ je střední hodnota této třídy

- Řešením jsou :
 - střední hodnoty $\hat{\boldsymbol{\mu}}_k$ spočítané z dat jednotlivých tříd
 - kovarianční matice $\boldsymbol{\Sigma}$, která je váhovaným průměrem kovariančních matic $\hat{\boldsymbol{\Sigma}}_k$ spočtených z dat jednotlivých tříd

$$\hat{\boldsymbol{\mu}}_k = \frac{1}{N_k} \sum_{n:t_n=k} \mathbf{x}_n \quad \hat{\boldsymbol{\Sigma}}_k = \frac{1}{N_k} \sum_{n:t_n=k} (\mathbf{x}_n - \hat{\boldsymbol{\mu}}_k)(\mathbf{x}_n - \hat{\boldsymbol{\mu}}_k)^T$$

$$\hat{\boldsymbol{\Sigma}} = \frac{1}{N} \sum_{k=1}^K N_k \hat{\boldsymbol{\Sigma}}_k = \frac{1}{N} \sum_{n=1}^N (\mathbf{x}_n - \hat{\boldsymbol{\mu}}_{t_n})(\mathbf{x}_n - \hat{\boldsymbol{\mu}}_{t_n})^T$$



- V případě kdy ovšem naše data nerespektují předpoklad gaussovských rozložení a sdílené kovarianční matice. Klasifikátor může selhat – fialová rozhodovací linie
- Lepší výsledky dostaneme s diskriminativně natrénovaným klasifikátorem, který bude vysvětlen později – zelená rozhodovací linie


Opakování LDA

- Snažíme se data promítnout do takového směru, kde
 - Maximalizujeme vzdálenost mezi středními hodnotami tříd
 - Minimalizujeme průměrnou varianci tříd
- Maximalizujeme tedy

$$m_k = \mathbf{w}^T \mathbf{m}_k$$

$$J(\mathbf{w}) = \frac{(m_2 - m_1)^2}{s_1^2 + s_2^2}$$

$$\mathbf{w} \propto \mathbf{S}_W^{-1}(\mathbf{m}_2 - \mathbf{m}_1).$$



$$s_k^2 = \sum_{n \in \mathcal{C}_k} (y_n - m_k)^2$$

- Pro dvě třídy je $\mathbf{w}$ totožné s tím které jsme obdrželi pro náš generativní klasifikátor.
- Generativní klasifikátor ovšem zvolí i práh w_0

Generativní model a zobecněný lineární klasifikátor


Nyní použijme zobecněný lineární klasifikátor

$$y(\mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x} + w_0)$$

kde stále platí, že $\mathbf{w}^T \mathbf{x} + w_0 = \ln \frac{p(\mathbf{x}|C_1)}{p(\mathbf{x}|C_2)} + \ln \frac{P(C_1)}{P(C_2)}$

a kde aktivační funkce je
logistická sigmoida

$$\sigma(a) = \frac{1}{1 + e^{-a}}$$



Potom lze hodnotu tohoto zobecněného lineárního klasifikátoru přímo interpretovat jako posteriorní pravděpodobnost třídy C_1

$$p(C_1|\mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x} + w_0)$$

Jiné generativní lineární klasifikátory



- Lineární klasifikátor dostaneme nejen pro gaussovské rozložení, ale pro celou třídu rozložení s exponenciální rodiny, které lze zapsat v následující formě:

$$p(\mathbf{x}|\boldsymbol{\lambda}_k, s) = \frac{1}{s} h\left(\frac{1}{s}\mathbf{x}\right) g(\boldsymbol{\lambda}_k) \exp\left\{\frac{1}{s}\boldsymbol{\lambda}_k^T \mathbf{x}\right\}$$

kde vektor $\boldsymbol{\lambda}_k$ má každá třída svůj vlastní, zatím co parametr s je sdíleny všemi třídami

Problém s více třídami

- Klasifikace
 - jeden proti všem
 - Každý s každým



Lineární klasifikátor – více tříd

- Nejlépe je mít jednu lineární funkci pro každou třídu k

$$y_k(\mathbf{x}) = \mathbf{w}_k^T \mathbf{x} + w_{k0}$$

- Vyber třídu s největším $y_k(\mathbf{x})$
- Rozhodovací linie je opět lineární dána

$$y_k(\mathbf{x}) = y_j(\mathbf{x})$$

- Kde k a j jsou dvě nejpravděpodobnější třídy pro dané $\mathbf{x}$

$$(\mathbf{w}_k - \mathbf{w}_j)^T \mathbf{x} + (w_{k0} - w_{j0}) = 0$$

- Pro dvě třídy řešení degraduje k tomu co už jsme viděli

Gaussovský lineární klasifikátor pro více tříd

- Opět modelujeme rozložení tříd gaussovským rozložením:

$$\ln p(\mathbf{x}|C_k) = -\frac{D}{2} \ln(2\pi) - \frac{1}{2} \ln|\Sigma| - \frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_k)^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}_k)$$

- Pokud náš model omezíme tak, že každá třída má svou střední $\boldsymbol{\mu}_k$ hodnotu, ale kovarianční matice $\boldsymbol{\Sigma}$ je společná pro obě třídy, tak můžeme psát:

$$P(C_k|\mathbf{x}) = \frac{p(\mathbf{x}, C_k)}{\sum_l p(\mathbf{x}, C_l)} = \frac{\exp(a_k + \text{const}(\mathbf{x}))}{\sum_l \exp(a_l + \text{const}(\mathbf{x}))} = \frac{\exp(a_k)}{\sum_l \exp(a_l)}$$

funkce
softmax

$$\ln p(\mathbf{x}, C_k) = a_k + \text{const}(\mathbf{x})$$

$$a_k = \mathbf{x}^T \mathbf{w}_k + w_{k0}$$

$$\mathbf{w}_k = \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k$$

$$w_{k0} = -\frac{1}{2} \boldsymbol{\mu}_k^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k + \ln P(C_k)$$

Konstanta, která nezáleží na třídě. Vykrátila by se ve funkci softmax a tedy ji nemusíme vůbec počítat

Odvození

$$\begin{aligned}\ln p(\mathbf{x}, C_k) &= \ln p(\mathbf{x}|C_k) + \ln P(C_k) \\&= -\frac{D}{2} \ln(2\pi) - \frac{1}{2} \ln|\Sigma| - \frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_k)^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_k) + \ln P(C_k) \\&= -\frac{D}{2} \ln(2\pi) - \frac{1}{2} \ln|\Sigma| - \frac{1}{2} \mathbf{x}^T \Sigma^{-1} \mathbf{x} + \mathbf{x}^T \Sigma^{-1} \boldsymbol{\mu}_k - \frac{1}{2} \boldsymbol{\mu}_k^T \Sigma^{-1} \boldsymbol{\mu}_k + \ln P(C_k) \\&= \text{const}(\mathbf{x}) + \mathbf{x}^T \mathbf{w}_k + w_{k0} = a_k + \text{const}(\mathbf{x})\end{aligned}$$

kde si uvědomíme, že $\text{const}(\mathbf{x})$ závisí na $\mathbf{x}$, ale nezávisí na třídě k ,

$$\mathbf{x}^T \Sigma^{-1} \boldsymbol{\mu}_k = \boldsymbol{\mu}_k^T \Sigma^{-1} \mathbf{x}$$

a tedy

$$\frac{1}{2} \mathbf{x}^T \Sigma^{-1} \boldsymbol{\mu}_k + \frac{1}{2} \boldsymbol{\mu}_k^T \Sigma^{-1} \mathbf{x} = \mathbf{x}^T \Sigma^{-1} \boldsymbol{\mu}_k$$

Softmax funkce

Vstupem softmax funkce je vektor

$$\text{softmax}_k(\mathbf{a}) = \frac{\exp(a_k)}{\sum_l \exp(a_l)} = P(C_k|\mathbf{x})$$

k -tý element
výstupu funkce

$$\text{softmax}\left(\begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_K \end{bmatrix}\right) = \frac{1}{\sum_l \exp(a_l)} \begin{bmatrix} \exp(a_1) \\ \exp(a_2) \\ \vdots \\ \exp(a_K) \end{bmatrix}$$

Funkce vrací
vektor hodnot
(pravděpodobností)

Převede vector logaritmu nenormalizovaných
pravděpodobností tříd na pravděpodobnosti tříd

$$\text{softmax}\left(\begin{bmatrix} \log P(C_1|\mathbf{x}) + \textit{const} \\ \log P(C_2|\mathbf{x}) + \textit{const} \\ \vdots \\ \log P(C_K|\mathbf{x}) + \textit{const} \end{bmatrix}\right) = \text{softmax}\left(\begin{bmatrix} \log P(\mathbf{x}, C_1) \\ \log P(\mathbf{x}, C_2) \\ \vdots \\ \log P(\mathbf{x}, C_K) \end{bmatrix}\right) = \begin{bmatrix} P(C_1|\mathbf{x}) \\ P(C_2|\mathbf{x}) \\ \vdots \\ P(C_K|\mathbf{x}) \end{bmatrix}$$

Gaussovský lineární klasifikátor pro více tříd II

$$P(C_k|\mathbf{x}) = \frac{p(\mathbf{x}, C_k)}{\sum_l p(\mathbf{x}, C_l)} = \frac{\exp(a_k + \text{const}(\mathbf{x}))}{\sum_l \exp(a_l + \text{const}(\mathbf{x}))} = \frac{\exp(a_k)}{\sum_l \exp(a_l)}$$

$$\ln p(\mathbf{x}, C_k) = a_k + \text{const}(\mathbf{x})$$

$$a_k = \mathbf{w}_k^T \mathbf{x} + w_{k0}$$

$$\mathbf{w}_k = \mathbf{\Sigma}^{-1} \boldsymbol{\mu}_k$$

$$w_{k0} = -\frac{1}{2} \boldsymbol{\mu}_k^T \mathbf{\Sigma}^{-1} \boldsymbol{\mu}_k + \ln P(C_k)$$

Pravděpodobností všech tříd můžeme tedy efektivně vypočítat jako

$$\begin{bmatrix} P(C_1|\mathbf{x}) \\ P(C_2|\mathbf{x}) \\ \vdots \\ P(C_K|\mathbf{x}) \end{bmatrix} = \text{softmax} \left(\begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_K \end{bmatrix} \right) = \text{softmax}(\mathbf{a}) = \text{softmax}(\mathbf{W}\mathbf{x} + \mathbf{w}_0)$$

kde $\mathbf{w}_k^T$ jsou řádky matice $\mathbf{W}$ a w_{k0} jsou koeficienty vektoru $\mathbf{w}_0$.

$$\mathbf{W} = [\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_K]^T \quad \mathbf{w}_0 = [w_{10}, w_{20}, \dots, w_{K0}]^T$$

Lineární logistická regrese pro více tříd

$$\begin{bmatrix} P(C_1|\mathbf{x}) \\ P(C_2|\mathbf{x}) \\ \vdots \\ P(C_K|\mathbf{x}) \end{bmatrix} = \text{softmax} \left(\begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_K \end{bmatrix} \right) = \text{softmax}(\mathbf{a}) = \text{softmax}(\mathbf{W}\mathbf{x})$$

kde opět předpokládáme $x_0 = 1$ a nemusíme tedy explicitně zavádět w_{k0} .
Nyní budeme parametry $\mathbf{W}$ odhadovat tak, abychom přímo maximalizovali pravděpodobnost anotací $\mathbf{t} = [t_1, t_2, \dots, t_N]^T$, tedy

$$P(\mathbf{t}|\mathbf{X}) = \prod_n P(t_n|\mathbf{x}_n) = \prod_n \text{softmax}_{t_n}(\mathbf{W}\mathbf{x}_n) = \prod_n \frac{\exp(\mathbf{w}_{t_n}^T \mathbf{x}_n)}{\sum_{l=1}^K \exp(\mathbf{w}_l^T \mathbf{x}_n)}$$

kde $\mathbf{w}_k^T$ je k -tý řádek matice $\mathbf{W}$ a t_n je index třídy n -tého trénovacího vzoru.

Všiměme si, že maximalizujeme stejnou onjektivní funkci jako pro při odhadu maximálně věrohodných parametrů diskrétního rozložení, jen je teď pravděpodobnost třídy podmíněna pozorováním $\mathbf{x}$.

Lineární logistická regrese – II.

- Místo maximalizování

$$P(\mathbf{t}|\mathbf{X}) = \prod_n P(t_n|\mathbf{x}_n) = \prod_n \text{softmax}_{t_n}(\mathbf{W}\mathbf{x}_n) = \prod_n \frac{\exp(\mathbf{w}_{t_n}^T \mathbf{x}_n)}{\sum_{l=1}^K \exp(\mathbf{w}_l^T \mathbf{x}_n)}$$

lidé ve strojovém učení často mluví o minimalizování ekvivalentní chybové funkce známé jako **křížová entropie (cross-entropy)**

$$E(\mathbf{W}) = -\ln P(\mathbf{t}|\mathbf{X}) = -\sum_{n=1}^N \ln P(t_n|\mathbf{x}_n) = -\sum_{n=1}^N \ln \frac{\exp(\mathbf{w}_{t_n}^T \mathbf{x}_n)}{\sum_{l=1}^C \exp(\mathbf{w}_l^T \mathbf{x}_n)}$$

- Hledáme minimum této funkce, takže derivujeme abychom dostali gradient

$$\nabla_{\mathbf{w}_j} E(\mathbf{W}) = \sum_{n=1}^N \left(\frac{\exp(\mathbf{x}_n^T \mathbf{w}_j)}{\sum_l \exp(\mathbf{x}_n^T \mathbf{w}_l)} - \delta(t_n = j) \right) \mathbf{x}_n$$

a hledáme takové $\mathbf{w}_j$ (pro všechna j) pro které $\nabla_{\mathbf{w}_j} E(\mathbf{W}) = \mathbf{0}$

Lineární logistická regrese – III.

Gradient můžeme počítat pro každý řádek matice $\mathbf{W}$ zvlášť

$$\nabla_{\mathbf{w}_j} E(\mathbf{W}) = \frac{\partial E(\mathbf{W})}{\partial \mathbf{w}_j} = \sum_{n=1}^N \left(\text{softmax}_j(\mathbf{W}\mathbf{x}_n) - \delta(t_n = j) \right) \mathbf{x}_n$$

Nebo můžeme rovnou počítat derivaci $E(\mathbf{W})$ podle celé matice $\mathbf{W}$

$$\frac{\partial E(\mathbf{W})}{\partial \mathbf{W}} = \sum_{n=1}^N \left(\text{softmax}(\mathbf{W}\mathbf{x}_n) - \text{onehot}(t_n) \right) \mathbf{x}_n^T = (\mathbf{Y} - \mathbf{T}) \mathbf{X}^T$$


- $\delta(i = j) = 1$ pokud $i = j$ a jinak je 0
- $\text{onehot}(k)$ je vektor nul a pouze k -tý element je 1
- $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N]$ je matice trénovacích vzorů (ve sloupcích)
- $\mathbf{T} = [\mathbf{t}_1, \mathbf{t}_2, \dots, \mathbf{t}_N]$ kde sloupce $\mathbf{t}_1 = \text{onehot}(t_n)$ jsou anotace
- $\mathbf{Y} = [\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_N]$ kde sloupce jsou predikované pravděpodobnosti tříd $\mathbf{y}_n = \text{softmax}(\mathbf{W}\mathbf{x}_n)$

Metoda gradientního sestupu

- Opakovaně měníme parametry tak, že jimi pohybujeme v malých krocích ve směru opačném ke gradientu $\nabla E(\mathbf{W})$ (tedy z kopce dolů) se nedostaneme do minima funkce kde $\nabla E(\mathbf{W}) = \mathbf{0}$

$$\mathbf{W}^{\tau+1} = \mathbf{W}^{\tau} - \eta \frac{\partial E(\mathbf{W}^{\tau})}{\partial \mathbf{W}}$$

- Učící konstanta (*learning rate*) η určuje jak velké kroky děláme a musí být správně nastavena aby algoritmus konvergoval



- Matematicky správně je gradient vektor, ale naše derivace $\frac{\partial E(\mathbf{W}^{\tau})}{\partial \mathbf{W}}$ je matice, tak abychom ji mohli použít přímo pro upravu matice parametrů $\mathbf{W}$.

softmax pro 2 třídy

$$\begin{aligned} P(C_1|\mathbf{x}) &= \text{softmax}_1 \left(\begin{bmatrix} a_1 \\ a_2 \end{bmatrix} \right) = \frac{\exp(a_1)}{\sum_l \exp(a_l)} = \frac{\exp(a_1)}{\exp(a_1) + \exp(a_2)} \\ &= \frac{1}{1 + \frac{\exp(a_2)}{\exp(a_1)}} = \frac{1}{1 + e^{-(a_1 - a_2)}} = \sigma(a_1 - a_2) \end{aligned}$$

- Pro dva vstupy, první výstup softmax_1 „degraduje“ na logistickou sigmoidu rozdílu vstupů
- Pro logistickou regresi se dvěmi třídami:

$$P(C_1|\mathbf{x}) = \text{softmax}_1(\mathbf{W}\mathbf{x}) = \text{softmax}_1([\mathbf{w}_1, \mathbf{w}_2]^T \mathbf{x}) = \sigma((\mathbf{w}_1 - \mathbf{w}_2)^T \mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x})$$

- A tedy logistická pro dvě třídy je jen speciálním případem kde $\mathbf{w} = \mathbf{w}_1 - \mathbf{w}_2$

$$P(\mathbf{t}|\mathbf{X}) = \prod_n P(t_n|\mathbf{x}_n) = \prod_n \text{softmax}_{t_n}(\mathbf{W}\mathbf{x}_n)$$


$$P(\mathbf{t}|\mathbf{X}) = \prod_n P(C_1|\mathbf{x}_n)^{t_n} P(C_2|\mathbf{x}_n)^{1-t_n} = \prod_n \sigma(\mathbf{x}_n^T \mathbf{w})^{t_n} (1 - \sigma(\mathbf{x}_n^T \mathbf{w}))^{1-t_n}$$

Lineární logistická regrese – 2 třídy

- Uvažujme opět pravděpodobnostní model, kde

$$P(C_1|\mathbf{x}) = \sigma(\mathbf{x}^T \mathbf{w})$$

a pravděpodobnost druhé třídy

$$P(C_2|\mathbf{x}) = 1 - P(C_1|\mathbf{x})$$

- kde opět předpokládáme $x_0 = 1$ a nemusíme tedy explicitně zavádět w_0 .
- Nyní budeme parametry $\mathbf{w}$ odhadovat tak, abychom přímo maximalizovali pravděpodobnost anotací $\mathbf{t} = [t_1, t_2, \dots, t_N]^T$, tedy

$$P(\mathbf{t}|\mathbf{X}) = \prod_n P(t_n|\mathbf{x}_n)$$

- Pro zjednodušení zápisu předpokládejme, že $t_n = 1$, pokud $\mathbf{x}_n$ patří do třídy C_1 a $t_n = 0$, pokud $\mathbf{x}_n$ patří do třídy C_2 . Potom můžeme psát

$$P(\mathbf{t}|\mathbf{X}) = \prod_n P(C_1|\mathbf{x}_n)^{t_n} P(C_2|\mathbf{x}_n)^{1-t_n} = \prod_n \sigma(\mathbf{x}_n^T \mathbf{w})^{t_n} (1 - \sigma(\mathbf{x}_n^T \mathbf{w}))^{1-t_n}$$

- Všiměme si, že maximalizujeme stejnou onjektivní funkci jako pro při odhadu maximálně věrohodných parametrů diskrétního rozložení, jen je teď pravděpodobnost třídy podmíněna pozorováním $\mathbf{x}$.

Lineární logistická regrese – 2 třídy – II.

- Místo maximalizování

$$P(\mathbf{t}|\mathbf{X}) = \prod_n P(t_n|\mathbf{x}_n) = \prod_n \sigma(\mathbf{x}_n^T \mathbf{w})^{t_n} (1 - \sigma(\mathbf{x}_n^T \mathbf{w}))^{(1-t_n)}$$

lidé ve strojovém učení často mluví o minimalizování ekvivalentní chybové funkce známé jako **křížová entropie (cross-entropy)**

$$E(\mathbf{w}) = -\ln P(\mathbf{t}|\mathbf{X}) = -\sum_{n=1}^N t_n \ln \sigma(\mathbf{x}_n^T \mathbf{w}) + (1 - t_n) \ln (1 - \sigma(\mathbf{x}_n^T \mathbf{w}))$$

- Hledáme minimum této funkce, takže derivujeme abychom dostali gradient

$$\nabla E(\mathbf{w}) = \sum_{n=1}^N (\sigma(\mathbf{x}_n^T \mathbf{w}) - t_n) \mathbf{x}_n$$

a hledáme takové $\mathbf{w}$ pro které $\nabla E(\mathbf{w}) = \mathbf{0}$

Lineární logistická regrese – 2 třídy – III.

- Pomocí maticového násobení můžeme

$$\nabla E(\mathbf{w}) = \sum_{n=1}^N (\sigma(\mathbf{x}_n^T \mathbf{w}) - t_n) \mathbf{x}_n$$

přepsat jako

$$\nabla E(\mathbf{w}) = \mathbf{X}(\mathbf{y} - \mathbf{t})$$

kde $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N]$ je matice trenovacích vzorů, $\mathbf{t} = [t_1, t_2, \dots, t_N]^T$ sloupcový vektor odpovídajících (0/1) anotací a $\mathbf{y} = [y_1, y_2, \dots, y_N]^T$ je sloupcový vektor výstupů klasifikátoru

$$y_n = P(C_1 | \mathbf{x}_n) = \sigma(\mathbf{x}_n^T \mathbf{w})$$



Vyjádření parametrů $\mathbf{w}$ pro $\nabla E(\mathbf{w}) = \mathbf{0}$ bohužel nemá analytické řešení a musíme přistoupit k numerické optimalizaci, např. pomocí metody gradientního sestupu (*gradient descent*)

Metoda gradientního sestupu

- Opakovaně měníme parametry tak, že jimi pohybujeme v malých krocích ve směru opačném ke gradientu $\nabla E(\mathbf{w})$ (tedy z kopce dolů) se nedostaneme do minima funkce kde $\nabla E(\mathbf{w}) = \mathbf{0}$

$$\mathbf{w}^{\tau+1} = \mathbf{w}^{\tau} - \eta \nabla E(\mathbf{w}^{\tau})$$

- Učící konstanta (*learning rate*) η určuje jak velké kroky děláme a musí být správně nastavena aby algoritmus konvergoval



Lineární logistická regrese: odhad parametrů

- Rychlejší konvergenci dosáhneme pomocí Newton-Raphson optimalizace:
 - Kolem stávajícího řešení $\mathbf{w}^\tau$ aproximujeme chybovou funkci ∇E pomocí Taylorova rozvoje druhého řádu, čímž obdržíme kvadratickou formu (vícerozměrné zobecnění kvadratické funkce).
 - Jako nové řešení zvolíme to, kde má tato kvadratická forma minimum.

$$\mathbf{w}^{\tau+1} = \mathbf{w}^\tau - \mathbf{H}(\mathbf{w}^\tau)^{-1} \nabla E(\mathbf{w}^\tau)$$

kde $\mathbf{H}(\mathbf{w}^\tau) = \mathbf{X}\mathbf{R}\mathbf{X}^T$ je matice druhých derivací (Hessian matrix).


$$\mathbf{w}^{\tau+1} = \mathbf{w}^\tau - (\mathbf{X}\mathbf{R}\mathbf{X}^T)^{-1} \mathbf{X}(\mathbf{y} - \mathbf{t})$$

- $\mathbf{R}$ je diagonální matice s diagonálou $\text{diag}(\mathbf{R}) = \mathbf{y}(1 - \mathbf{y})$
- Pozor! Stejně jako i metody gradientního sestupu není zaručeno, že každý krok zlepšení řešení. Metoda může začít divergovat, ale dá se řešit např. (opakovaným) půlením kroku $\mathbf{w}^{\tau+1} := (\mathbf{w}^{\tau+1} + \mathbf{w}^\tau)/2$.

Logistická regrese – příklad


$$P(C_1|\mathbf{x}) = \sigma(\mathbf{x}^T \mathbf{w}) = \sigma(w_1 x_1 + w_2 x_2 + w_0)$$

Na “překřývajících se třídách” se korektně naučíme odhadovat $P(C_1|\mathbf{x})$



Na “oddělených třídách” může dojít k přetrénování, kde $E(\mathbf{w}) \approx \mathbf{0}$, i když řešení není uspokojivé.

Koeficienty w_1 a w_2 jsou příliš velké $\Rightarrow$ rychlá změna $P(C_1|\mathbf{x})$



Regularizace parametrů

- Do objektivní funkce přidáme regularizační člen

$$\lambda \|\mathbf{w}\|_2^2 = \lambda \mathbf{w}^T \mathbf{w} = \lambda \sum_{d=1}^D w_d^2$$

který penalizuje vysoké hodnoty w_1 a w_2 .

$$E(\mathbf{w}) = - \sum_{n=1}^N t_n \ln \sigma(\mathbf{x}_n^T \mathbf{w}) + (1 - t_n) \ln(1 - \sigma(\mathbf{x}_n^T \mathbf{w})) + \lambda \mathbf{w}^T \mathbf{w}$$

- Potom


$$\nabla E(\mathbf{w}) = \mathbf{X}(\mathbf{y} - \mathbf{t}) + \lambda \mathbf{w} \quad \mathbf{H}(\mathbf{w}^{\tau}) = \lambda \mathbf{I} + \mathbf{X} \mathbf{R} \mathbf{X}^T$$

$$\mathbf{w}^{\tau+1} = \mathbf{w}^{\tau} - (\lambda \mathbf{I} + \mathbf{X} \mathbf{R} \mathbf{X}^T)^{-1} (\mathbf{X}(\mathbf{y} - \mathbf{t}) + \lambda \mathbf{w}^{\tau})$$


- Zde pro jednoduchost regularizujeme i w_0 , ale je lepší to nedělat abycho nestahovali rozhodovací hranici k počátku.

Příklady pro různé hodnoty regularizačního koeficientu λ


$\lambda = 0$




$\lambda = 2$



$\lambda = 200$





$\lambda = 20\,000$



Nelineární mapování vstupního vektoru

- Nelze-li původní data lineárně oddělit, možná pomůže jejich nelineární transformace do potenciálně vysokerozměrného prostoru – hlavní myšlenka „kernel methods“ které budou vysvětleny příště
- V našem příkladu pomohlo i mapování dvourozměrných dat do dvou gaussovských funkcí



Lineární logistická regrese: nelineární klasifikace

- Nelineárně transformujeme vstupy $\mathbf{x}$ do vícerozměrného vektoru $\hat{\mathbf{x}}$.
- Jako příklad použijeme transformaci pomocí polynomů druhého řádu:
$$\hat{\mathbf{x}} = [1, \quad x_1, \quad x_2, \quad x_1x_2, \quad x_1^2, \quad x_2^2]$$
- Nyní natrénujeme a aplikujeme logistickou regresi nad těmito vícerozměrnými daty. Jakou pravděpodobnost $P(C_1|\mathbf{x})$ odhaduje takový model jako funkci původních dvourozměrných dat $\mathbf{x}$?

- Rozhodovací linie je kuželosečka (jako u gaussovského klasifikátoru).

